

Memorie RAM: mercato italiano vs tedesco

Pipeline ETL, Data Quality e Modellazione NoSQL
per l'analisi multi-mercato E-Commerce (Idealo
IT/DE)

1. CONTESTO DI BUSINESS E OBIETTIVI DEL PROGETTO



Scenario, obiettivi e stakeholder

- **Contesto:** Il mercato e-commerce delle memorie RAM (DDR4 e DDR5) è caratterizzato da forte dinamicità dei prezzi, variabilità di specifiche tecniche e differenze tra mercati geografici.
- **Obiettivo:** Costruire un repository dati pulito e strutturato che permetta il confronto sistematico tra i mercati e-commerce italiano (IT) e tedesco (DE) per memorie RAM DDR4/DDR5, come base per analisi comparative di prezzo e assortimento.
- **Domande di Analisi:**
 - Qual è il differenziale di prezzo medio tra mercato italiano e tedesco, distinto per categoria DDR4 e DDR5?
 - Come si distribuisce l'assortimento di prodotti (numero di SKU disponibili) tra i due mercati e le due categorie di memoria?
 - Esistono differenze sistematiche nella fascia di capacità/prestazioni (GB, frequenza) offerta tra i due mercati?
 - La numerosità e la varietà dell'offerta DDR5 riflettono già una piena maturità del mercato, o DDR4 resta dominante in termini di assortimento?
- **Stakeholder:**
 - E-Commerce / Pricing Analyst (benchmark prezzi concorrenza).
 - System Integrators / PC Builders (ricerca miglior rapporto costo/GB).
 - Consumatori Tech (scelta componenti ottimale).

Scope del progetto

In Scope (Realizzato):

- **Cattura dati grezzi:** Estrazione manuale delle **response** JSON dal tab *Network* del browser sulle pagine Idealo (IT e DE).
- **Caricamento Batch:** Script Python (**pymongo**) per l'importazione dei JSON nelle collezioni MongoDB *Source*.
- **Parsing & Normalizzazione:** Feature Extraction tramite regex multi-lingua (IT/DE) e strategie di fallback.
- **Deduplicazione:** Gestione della deduplicazione esatta e gerarchica Parent/Child (**mainProductId**).
- **Data Quality Profiling:** Profilazione su 4 dimensioni (Completeness, Uniqueness, Validity, Consistency).
- **Data Warehouse:** Consolidazione finale nella collection **dw_ram_products**.

Out of Scope / Limiti:

- Web scraping e ingestion automatizzata (i dati provengono da dump manuali delle chiamate di rete).
- Analisi temporale/storica (i dati attuali rappresentano uno snapshot puntuale).

2. DATASET E ARCHITETTURA TECNOLOGICA



Origine e caratteristiche del dataset (Source Layer)

- **Fonte dati:** Pagine e-commerce Idealo dedicate alle memorie RAM.
- **Struttura grezza:** File JSON contenenti un array di oggetti **items** unitamente a metadati di pagina (**filterGroups**, **pagination**).
- **Partizionamento iniziale (4 Collezioni Source in MongoDB):**
 - **sc_ram_ddr4_it | sc_ram_ddr4_de** (5 pagine JSON per mercato, ~180 item grezzi/coll)
 - **sc_ram_ddr5_it | sc_ram_ddr5_de** (5 pagine JSON per mercato, ~180 item grezzi/coll)
- **Volume grezzo totale:** 20 file JSON / 720 elementi grezzi complessivi.

```
{
  "id": "200174645",
  "hashedProductId": "134c580aa7c2a383859d7bb131bce5e7d6e47db34cc5255af3394d187ab3d8f1",
  "offerId": "44b5a6aee2d8bd5199433d1467c14a",
  "title": "Kingston ValueRam 16GB DDR4-3200 CL22 (RV932N22D8/16)",
  "category": "433D",
  "subheading": "RAM DDR4",
  "characteristics": {
    "RAM DDR4",
    "16 GB",
    "Modulo 1x",
    "Capacità modulo 16 GB",
    "3.200 MT/s",
    "Tempo di latenza CL 22-22-22",
    "Multitaglio 1,2 V",
    "UDIMM",
    "Verde"
  },
  "productId": "",
  "userReviewCount": null,
  "formattedTestRating": null,
  "roundedRating": null,
  "image": "https://cdn.idealo.com/folder/Product/200174/6/200174645/a18_productid_mittelgroesse/kingston-value-ram-16gb-ddr4-3200-cl22-kvr32n22d8-16.jpg",
  "href": "https://www.idealo.it/confronta-prezzi/200174645/kingston-value-ram-16gb-ddr4-3200-cl22-kvr32n22d8-16.html",
  "isRelevant": true,
  "offerInfo": {
    "formattedPrice": "€ 120,94",
    "offerCount": 17,
    "usedOnly": false,
    "formattedBasePrice": null,
    "leadoutHref": "https://www.idealo.it/calculator/calculator?offerKey=44b5a6aee2d8bd5199433d1467c14a&price=120,94&id=331517&type=offer&pos=1"
  },
  "energyInfo": null,
  "bargainInfo": null,
  "retailMediaInfo": null,
  "type": "PRODUCT",
  "shopInfo": {
    "shopId": "331517",
    "shopPageUrl": "",
    "shopName": "PC Componentes IT",
    "shopImage": "https://cdn.idealo.com/folder/Shop/331/5/331517/a10_shop_80x30.png",
    "deliveryInformation": null,
    "deliveryStatus": null,
    "shippingCost": "€ 0,00",
    "shippingComment": null,
    "shippingIsFreeOfCharge": false,
    "isMerchant": false,
    "merchantId": null,
    "shippingCostShop": null,
    "freeReturnShipping": null,
    "freeReturnDays": null
  },
  "voucherDisclaimer": null,
  "voucherCode": null,
  "lastUpdated": null,
  "rawPrice": 120.94,
  "isBestSeller": false,
  "bestSellerInfo": null,
  "hasProAndCons": false,
  "sources": [
    "opensearch"
  ],
  "visualSearchItems": []
}
```

Esempio di response JSON catturata via DevTools Network tab (idealo.it), singolo elemento dell'array **items**; il file completo include anche **filterGroups** e **pagination** a livello di pagina

Architettura dati

FILE JSON GREZZI


Estrazione manuale



01_load_source.ipynb

SOURCE LAYER

Raw Data




20 file JSON
(~180 item / collezione)
via DevTools Network tab

Archiviazione as-is dei
documenti JSON estratti

02_build_staging.ipynb

STAGING LAYER

Clean & Parsed



Unpacking, parsing regex,
deduplicazione, profiling

03_build_dwh.ipynb

DATA WAREHOUSE LAYER

Consolidated



Consolidamento +
arricchimento con
market / ram_category

Stack tecnologico ed ambiente di sviluppo

- **Database NoSQL:** MongoDB Atlas (Database: `idealo_ram`).
- **Linguaggi & Librerie:** Python, pandas, pymongo, re (Regular Expressions)
- **Pipeline e Notebook Modulari:**
 - a. `01_load_source.ipynb`: Caricamento batch dei JSON grezzi (catturati manualmente via DevTools) in MongoDB Source (`sc_ram_*`)
 - b. `02_build_staging.ipynb`: Pulizia, Parsing Regex, Deduplicazione e Quality Assessment → 4 collezioni MongoDB Staging (`st_ram_*`)
 - c. `03_build_dwh.ipynb`: Consolidamento finale, arricchimento con `market/ram_category`, sanitizzazione BSON → `dw_ram_products`

3. PIPELINE ETL E DATA QUALITY ASSESSMENT



Pulizia e selezione dei campi (Staging Layer)

- **Unpacking:** Estratta la lista interna `items` ed eliminati oltre 15 campi irrilevanti o sistematicamente nulli (`energyInfo`, `voucherCode`, `retailMediaInfo`, `sources`).
- **Campi Selezionati e Mantenuti:**
 - a. *Identificativi:* `id`, `offerId`, `title`.
 - b. *Commerciali:* `rawPrice`, `shopName`, `shippingCosts`, `shippingIsFreeOfCharge`.
 - c. *Reputazionali:* `userReviewCount`, `roundedRating`.
 - d. *Attributi Hardware Estratti:* Capacità, Frequenza, Latenza, Voltaggio, Form Factor.

Feature extraction via regex multi-lingua e fallback logic

Sfida: Attributi non strutturati e localizzati in lingua mista IT/DE all'interno del campo **characteristics** ("Moduli 2" vs "Anzahl Module 2").

Soluzione Regex Content-Based:

- Capacità totale: **(\d+)\s?GB**
- Frequenza: **([\d\.]+)\s?MT/s**
- Voltaggio: **([\d,\.\.]+)\s?V\$**

Fallback Cross-Field (CAS Latency): Se la latenza CAS non è presente in **characteristics** (~30% dei casi), viene recuperata via regex **CL(\d+)** analizzando il campo **title** del prodotto (recuperato ~50% dei dati mancanti).

Deduplicazione

- **Livello 1 – Deduplicazione esatta:**
Serializzazione JSON delle righe per eliminare i duplicati identici preservando oggetti non-hashable.
- **Livello 2 – Deduplicazione gerarchica Parent/Child (**mainProductId**):**
 - a. *Ipotesi iniziale:* si assumeva che le coppie parent/child condividessero sempre prezzo e venditore.
 - b. *Verifica sui dati:* l'analisi ha mostrato che ~34% delle coppie collegate in DDR5 presentava rawPrice e/o shopName differenti, smentendo l'assunzione iniziale.
 - c. *Regola applicata (corretta):* il parent viene rimosso solo se rawPrice e shopName coincidono esattamente con quelli del child; altrimenti entrambi vengono mantenuti come offerte commerciali distinte.

Data Quality Assessment (Misure e Profiling)

Valutazione sistematica condotta su 4 dimensioni di data quality nei dati di Staging:

1. **Completeness:** >97% sui campi chiave (Capacità, Frequenza); latenza primaria portata a 80-99% tramite il fallback dal titolo.
2. **Uniqueness:** 0 duplicati esatti residui (verificati tramite **offerId** come chiave univoca); corretta preservazione delle varianti di prezzo.
 - a. Approfondimento: Duplicati "apparenti" vs coppie cross-market legittime: l'analisi ha rilevato 151 gruppi di record con **id** duplicato. Un controllo puntuale ha confermato che non si tratta di errori di deduplicazione, bensì di coppie legittime dello stesso prodotto fisico offerto sia sul mercato IT sia su quello DE, mantenute intenzionalmente distinte perché rappresentano transazioni indipendenti nei due paesi.
3. **Validity:** 100% di conformità ai domain constraint ($\text{Price} > 0$, $1600 \leq \text{MT/s} \leq 8400$, $1.0 \leq V \leq 1.6$).
4. **Consistency:** 100% di coerenza sulla regola d'affare $\text{Capacità Totale} = \text{Capacità Modulo} * \text{Numero Moduli}$.

4. DATA WAREHOUSE FINALE E CRITICITÀ



Integrazione e costruzione del Data Warehouse

Consolidamento staging: Concatenazione dei 4 dataset puliti (`st_ram_*`).

Arricchimento schema: Inserimento dei campi dimensionali di contesto:

- `market: 'IT' | 'DE'`
- `ram_category: 'DDR4' | 'DDR5'`

Perché Single Collection: In staging i dati erano già separati in 4 collezioni per mercato/categoria. Le domande di analisi del progetto, però, sono tutte comparative cross-market/categoria. Con una singola collection queste query diventano una sola aggregation pipeline, invece di richiedere query multiple o `$unionWith` tra collezioni separate. La denormalizzazione (stessa struttura ripetuta riga per riga, invece di normalizzare in dimensioni separate) è utilizzata qui perché il caso d'uso è analitico e non transazionale.

Volumetria finale e Modellazione DWH (dw_ram_products)

Totale Documenti Consolidati: 656 record

Distribuzione Dettagliata per Categoria e Mercato:

- **Germania (DE):** 174 prodotti DDR4 | 156 prodotti DDR5 (Totale: 330)
- **Italia (IT):** 174 prodotti DDR4 | 152 prodotti DDR5 (Totale: 326)

Modello DWH: Modellazione denormalizzata su Single Collection (Flat Approach), ottimizzata per query analitiche NoSQL e aggregazioni ad alte prestazioni.

```
{
  "id": "200174645",
  "offerId": "44b5a6aeed2d6bde5199433d1467c14a",
  "title": "Kingston ValueRam 16GB DDR4-3200 CL22 (KVR32N22D8/16)",
  "subheading": "RAM DDR4",
  "userReviewCount": null,
  "roundedRating": null,
  "rawPrice": 120.94,
  "offerCount": 17,
  "usedOnly": false,
  "shopName": "PC Componentes IT",
  "shippingCosts": 0.0,
  "shippingIsFreeOfCharge": false,
  "isBestseller": false,
  "total_capacity_gb": 16.0,
  "module_capacity_gb": 16.0,
  "num_modules": 1.0,
  "frequency_mts": 3200.0,
  "cas_latency_raw": "CL 22-22-22",
  "cas_latency_primary": 22.0,
  "voltage_v": 1.2,
  "form_factor": "UDIMM",
  "market": "IT",
  "ram_category": "DDR4"
}
```

Criticità tecniche incontrate e soluzioni

Incompatibilità BSON / Pandas NaN:

- *Problema:* Pandas converte i valori assenti in float NaN, scritti su MongoDB come NaN numerici invece di null, invalidando le query.
- *Soluzione:* Implementazione di una funzione `sanitize_nans()` prima dell'operazione di `insert_many`.

Parsing Multilingua ed Encoding:

- *Problema:* Discrepanze nei separatori decimali (virgole vs punti) e caratteri speciali non formattati.
- *Soluzione:* Normalizzazione preventiva delle stringhe con stripping degli spazi non formattabili.

Un sistema di bot detection avanzato (fingerprinting TLS/comportamentale) blocca sistematicamente ogni tentativo di scraping automatizzato:

- *Problema:* Selenium → rilevato; Playwright-stealth → rilevato; curl_cffi (impersonation TLS) → rilevato
- *Soluzione:* estrazione manuale delle response JSON via DevTools Network tab, con approccio incrementale documentato

Sviluppi futuri e conclusioni

Obiettivi raggiunti:

- Repository dati puliti, deduplicati e comparabili costruito con successo (656 record consolidati, 4 dimensioni di data quality validate)
- Base dati pronta per il confronto sistematico tra i mercati IT e DE

Utilità: Il repository costruito fornisce una base dati affidabile e riutilizzabile per pricing analyst, system integrator e consumatori tech, superando le criticità di qualità tipiche dei dati e-commerce grezzi (duplicati, inconsistenze multilingua, valori mancanti).

Sviluppi futuri:

- Automatizzare l'ingestion tramite uno scraper o pipeline schedulata
- Estendere la copertura ad altri marketplace europei (es. FR, ES) riutilizzando i pattern regex language-agnostic già sviluppati