

Memorie RAM: mercato italiano vs tedesco

Pipeline ETL, Data Quality e Modellazione NoSQL
per l'analisi multi-mercato E-Commerce (Idealo
IT/DE)

1. CONTESTO DI BUSINESS E OBIETTIVI DEL PROGETTO



Scenario, obiettivi e stakeholder

- **Contesto:** Il mercato e-commerce delle memorie RAM (DDR4 e DDR5) è caratterizzato da forte dinamicità dei prezzi, variabilità di specifiche tecniche e differenze tra mercati geografici.
- **Obiettivo:** Costruire un repository dati pulito e strutturato che permetta il confronto sistematico tra i mercati e-commerce italiano (IT) e tedesco (DE) per memorie RAM DDR4/DDR5, come base per analisi comparative di prezzo e assortimento.
- **Domande di Analisi:**
 - Qual è il differenziale di prezzo medio tra mercato italiano e tedesco, distinto per categoria DDR4 e DDR5?
 - Come si distribuisce l'assortimento di prodotti (numero di SKU disponibili) tra i due mercati e le due categorie di memoria?
 - Esistono differenze sistematiche nella fascia di capacità/prestazioni (GB, frequenza) offerta tra i due mercati?
 - La numerosità e la varietà dell'offerta DDR5 riflettono già una piena maturità del mercato, o DDR4 resta dominante in termini di assortimento?
- **Stakeholder:**
 - E-Commerce / Pricing Analyst (benchmark prezzi concorrenza).
 - System Integrators / PC Builders (ricerca miglior rapporto costo/GB).
 - Consumatori Tech (scelta componenti ottimale).

Scope del progetto

In Scope (Realizzato):

- **Cattura dati grezzi:** Estrazione manuale delle **response** JSON dal tab *Network* del browser sulle pagine Idealo (IT e DE).
- **Caricamento Batch:** Script Python (**pymongo**) per l'importazione dei JSON nelle collezioni MongoDB *Source*.
- **Parsing & Normalizzazione:** Feature Extraction tramite regex multi-lingua (IT/DE) e strategie di fallback.
- **Deduplicazione:** Gestione della deduplicazione esatta e gerarchica Parent/Child (**mainProductId**).
- **Data Quality Profiling:** Profilazione su 4 dimensioni (Completeness, Uniqueness, Validity, Consistency).
- **Data Warehouse:** Consolidazione finale nella collection **dw_ram_products**.

Out of Scope / Limiti:

- Web scraping e ingestion automatizzata (i dati provengono da dump manuali delle chiamate di rete).
- Analisi temporale/storica (i dati attuali rappresentano uno snapshot puntuale).

2. DATASET E ARCHITETTURA TECNOLOGICA




Origine e caratteristiche del dataset (Source Layer)

- **Fonte dati:** Pagine e-commerce Idealo dedicate alle memorie RAM.
- **Struttura grezza:** File JSON contenenti un array di oggetti **items** unitamente a metadati di pagina (**filterGroups**, **pagination**).
- **Partizionamento iniziale (4 Collezioni Source in MongoDB):**
 - **sc_ram_ddr4_it | sc_ram_ddr4_de** (5 pagine JSON per mercato, ~180 item grezzi/coll)
 - **sc_ram_ddr5_it | sc_ram_ddr5_de** (5 pagine JSON per mercato, ~180 item grezzi/coll)
- **Volume grezzo totale:** 20 file JSON / 720 elementi grezzi complessivi.

```
{
  "id": "200174645",
  "hashedProductId": "134c580aa7c2a383859d7db131b05e7d647db34cc5255af339d187abb3dbf1",
  "offerId": "44b5afaeae20bde5199433d1467c14a",
  "title": "Kingston ValueRam 16GB DDR4-3200 CL22 (RV32N2208/16)",
  "category": "RAM",
  "subcategory": "RAM DDR4",
  "characteristics": {
    "RAM DDR4",
    "16 GB",
    "Moduli 1*",
    "Capacità modulo 16 GB",
    "3.200 MHz",
    "Tempo di latenza CL 22-22-22",
    "Voltaggio 1,2 V",
    "UDIMM",
    "Vedda"
  },
  "mainProductId": "",
  "userReviewCount": null,
  "formattedTestRating": null,
  "roundedRating": null,
  "image": "https://cdn.idealio.com/folder/Product/200174/6/200174645/x10_productid_mktai_gross/Kingston-value-ram-16gb-ddr4-3200-cl22-kvr32n2208-16.jpg",
  "url": "https://www.idealio.it/confronta-prezzi/200174645/kingston-value-ram-16gb-ddr4-3200-cl22-kvr32n2208-16.html",
  "isAvailable": true,
  "offerInfo": {
    "formattedPrice": "€ 120,94",
    "offerCount": 17,
    "usedOnly": false,
    "formattedBasePrice": null,
    "leadoutHref": "https://www.idealio.it/locator/relocate?offerKey=44b5afaeae20bde5199433d1467c14a&price=120.94&id=331517&type=offer&pos=1"
  },
  "energyInfo": null,
  "bargainInfo": null,
  "retailMediaInfo": null,
  "type": "PRODUCT",
  "shopInfo": {
    "shopId": "331517",
    "shopPageUrl": "",
    "shopName": "PC Componentes IT",
    "shopImage": "https://cdn.idealio.com/folder/shop/331/5/331517/x10_shop_90x30.png",
    "deliveryInformation": null,
    "deliveryStatus": null,
    "shippingCost": "€ 0,00",
    "shippingComment": null,
    "shippingIsFreeOfCharge": false,
    "isMerchant": false,
    "merchantId": null,
    "shippingCostMap": null,
    "freeReturnShipping": null,
    "freeReturnDays": null
  },
  "voucherDisclaimer": null,
  "voucherCode": null,
  "lastUpdated": null,
  "rawPrice": 120.94,
  "lastSeller": false,
  "bestSellerInfo": null,
  "hasProAndCons": false,
  "sources": [
    "opensearch"
  ],
  "visualSearchItems": []
}
```

Esempio di response JSON catturata via DevTools Network tab (idealio.it), singolo elemento dell'array **items**; il file completo include anche **filterGroups** e **pagination** a livello di pagina

Architettura dati



Stack tecnologico ed ambiente di sviluppo

- **Database NoSQL:** MongoDB Atlas (Database: `idealo_ram`).
- **Linguaggi & Librerie:** Python, pandas, pymongo, re (Regular Expressions)
- **Pipeline e Notebook Modulari:**
 - a. `01_load_source.ipynb`: Caricamento batch dei JSON grezzi (catturati manualmente via DevTools) in MongoDB Source (`sc_ram_*`)
 - b. `02_build_staging.ipynb`: Pulizia, Parsing Regex, Deduplicazione e Quality Assessment → 4 collezioni MongoDB Staging (`st_ram_*`)
 - c. `03_build_dwh.ipynb`: Consolidamento finale, arricchimento con `market/ram_category`, sanitizzazione BSON → `dw_ram_products`
 - d. `04_viz_comparison.ipynb`: Esportazione del DWH consolidato in formato CSV e creazione grafici mediante la libreria python matplotlib

3. PIPELINE ETL E DATA QUALITY ASSESSMENT



Pulizia e selezione dei campi (Staging Layer)

- **Unpacking:** Estratta la lista interna `items` ed eliminati oltre 15 campi irrilevanti o sistematicamente nulli (`energyInfo`, `voucherCode`, `retailMediaInfo`, `sources`).
- **Campi Selezionati e Mantenuti:**
 - a. *Identificativi:* `id`, `offerId`, `title`.
 - b. *Commerciali:* `rawPrice`, `shopName`, `shippingCosts`, `shippingIsFreeOfCharge`.
 - c. *Reputazionali:* `userReviewCount`, `roundedRating`.
 - d. *Attributi Hardware Estratti:* Capacità, Frequenza, Latenza, Voltaggio, Form Factor.

Feature extraction via regex multi-lingua e fallback logic

Sfida: Attributi non strutturati e localizzati in lingua mista IT/DE all'interno del campo **characteristics** ("Moduli 2" vs "Anzahl Module 2").

Soluzione Regex Content-Based:

- Capacità totale: **(\d+)\s?GB**
- Frequenza: **([\d\\.]+)\s?MT/s**
- Voltaggio: **([\d,\\.]+)\s?V\$**

Fallback Cross-Field (CAS Latency): Se la latenza CAS non è presente in **characteristics** (~30% dei casi), viene recuperata via regex **CL(\d+)** analizzando il campo **title** del prodotto (recuperato ~50% dei dati mancanti).

Deduplicazione

- **Livello 1 – Deduplicazione esatta:**
Serializzazione JSON delle righe per eliminare i duplicati identici preservando oggetti non-hashable.
- **Livello 2 – Deduplicazione gerarchica Parent/Child (**mainProductId**):**
 - a. *Ipotesi iniziale:* si assumeva che le coppie parent/child condividessero sempre prezzo e venditore.
 - b. *Verifica sui dati:* l'analisi ha mostrato che ~34% delle coppie collegate in DDR5 presentava rawPrice e/o shopName differenti, smentendo l'assunzione iniziale.
 - c. *Regola applicata (corretta):* il parent viene rimosso solo se rawPrice e shopName coincidono esattamente con quelli del child; altrimenti entrambi vengono mantenuti come offerte commerciali distinte.

Data Quality Assessment (Misure e Profiling)

Valutazione sistematica condotta su 4 dimensioni di data quality nei dati di Staging:

1. **Completeness:** >97% sui campi chiave (Capacità, Frequenza); latenza primaria portata a 80-99% tramite il fallback dal titolo.
2. **Uniqueness:** 0 duplicati esatti residui (verificati tramite **offerId** come chiave univoca); corretta preservazione delle varianti di prezzo.
 - a. Approfondimento: Duplicati "apparenti" vs coppie cross-market legittime: l'analisi ha rilevato 151 gruppi di record con **id** duplicato. Un controllo puntuale ha confermato che non si tratta di errori di deduplicazione, bensì di coppie legittime dello stesso prodotto fisico offerto sia sul mercato IT sia su quello DE, mantenute intenzionalmente distinte perché rappresentano transazioni indipendenti nei due paesi.
3. **Validity:** 100% di conformità ai domain constraint ($\text{Price} > 0$, $1600 \leq \text{MT/s} \leq 8400$, $1.0 \leq V \leq 1.6$).
4. **Consistency:** 100% di coerenza sulla regola d'affare $\text{Capacità Totale} = \text{Capacità Modulo} * \text{Numero Moduli}$.

4. DATA WAREHOUSE FINALE E CRITICITÀ



Integrazione e costruzione del Data Warehouse

Consolidamento staging: Concatenazione dei 4 dataset puliti (`st_ram_*`).

Arricchimento schema: Inserimento dei campi dimensionali di contesto:

- `market: 'IT' | 'DE'`
- `ram_category: 'DDR4' | 'DDR5'`

Perché Single Collection: In staging i dati erano già separati in 4 collezioni per mercato/categoria. Le domande di analisi del progetto, però, sono tutte comparative cross-market/categoria. Con una singola collection queste query diventano una sola aggregation pipeline, invece di richiedere query multiple o `$unionWith` tra collezioni separate. La denormalizzazione (stessa struttura ripetuta riga per riga, invece di normalizzare in dimensioni separate) è utilizzata qui perché il caso d'uso è analitico e non transazionale.

Volumetria finale e Modellazione DWH (dw_ram_products)

Totale Documenti Consolidati: 656 record

Distribuzione Dettagliata per Categoria e Mercato:

- **Germania (DE):** 174 prodotti DDR4 | 156 prodotti DDR5 (Totale: 330)
- **Italia (IT):** 174 prodotti DDR4 | 152 prodotti DDR5 (Totale: 326)

Modello DWH: Modellazione denormalizzata su Single Collection (Flat Approach), ottimizzata per query analitiche NoSQL e aggregazioni ad alte prestazioni.

```
{
  "id": "200174645",
  "offerId": "44b5a6aeed2d6bde5199433d1467c14a",
  "title": "Kingston ValueRam 16GB DDR4-3200 CL22 (KVR32N22D8/16)",
  "subheading": "RAM DDR4",
  "userReviewCount": null,
  "roundedRating": null,
  "rawPrice": 120.94,
  "offerCount": 17,
  "usedOnly": false,
  "shopName": "PC Componentes IT",
  "shippingCosts": 0.0,
  "shippingIsFreeOfCharge": false,
  "isBestseller": false,
  "total_capacity_gb": 16.0,
  "module_capacity_gb": 16.0,
  "num_modules": 1.0,
  "frequency_mts": 3200.0,
  "cas_latency_raw": "CL 22-22-22",
  "cas_latency_primary": 22.0,
  "voltage_v": 1.2,
  "form_factor": "UDIMM",
  "market": "IT",
  "ram_category": "DDR4"
}
```

Criticità tecniche incontrate e soluzioni

Incompatibilità BSON / Pandas NaN:

- *Problema:* Pandas converte i valori assenti in float NaN, scritti su MongoDB come NaN numerici invece di null, invalidando le query.
- *Soluzione:* Implementazione di una funzione `sanitize_nans()` prima dell'operazione di `insert_many`.

Parsing Multilingua ed Encoding:

- *Problema:* Discrepanze nei separatori decimali (virgole vs punti) e caratteri speciali non formattati.
- *Soluzione:* Normalizzazione preventiva delle stringhe con stripping degli spazi non formattabili.


Un sistema di bot detection avanzato (fingerprinting TLS/comportamentale) blocca sistematicamente ogni tentativo di scraping automatizzato:

- *Problema:* Selenium → rilevato; Playwright-stealth → rilevato; curl_cffi (impersonation TLS) → rilevato
- *Soluzione:* estrazione manuale delle response JSON via DevTools Network tab, con approccio incrementale documentato

5. RISULTATI: CONFRONTO IT vs DE



Distribuzione dei prezzi: Italia vs Germania




- La mediana DDR4 è quasi identica nei due mercati
- DDR5 mostra una mediana più alta in Germania rispetto all'Italia
- DDR5 ha una dispersione (IQR) e outlier più marcati rispetto a DDR4 in entrambi i mercati, coerente con la presenza di kit enterprise ad alta capacità


Utilizzo di valori in scala logaritmica al fine di una migliore visualizzazione

Prezzo medio e mediano


Prezzo medio per mercato e categoria



Prezzo mediano per mercato e categoria




Stesso prodotto, prezzo diverso: IT vs DE



- La maggior parte dei prodotti si allinea vicino alla diagonale (prezzo simile nei due mercati), soprattutto DDR4
- A differenza del precedente confronto aggregato, qui si osserva lo stesso prodotto venduto in entrambi i mercati. Tale confronto punto-per-punto esclude che le differenze osservate siano dovute a un mix di prodotti differente tra i due mercati. Inoltre i punti DDR5 mostrano una dispersione sopra la diagonale più marcata dei DDR4
- Un solo kit enterprise DDR5 (fuori scala, ~7.800 € in DE) rappresenta un caso limite escluso dallo zoom


Top 15 prodotti per differenza di prezzo

Top 15 prodotti per differenza di prezzo assoluta (IT - DE)




- 14 dei 15 prodotti con maggior scarto sono più cari in Germania, un solo kit (Kingston FURY Beast 128GB) è invece più caro in Italia
- i kit ad alta capacità (64-256GB) dominano la classifica, coerente con l'osservazione che i kit enterprise DDR5 spingono il differenziale IT/DE

Numero di SKU: IT vs DE




Distribuzione per capacità e frequenza


DDR4 — Distribuzione capacità: IT vs DE




DDR4 — Distribuzione frequenza: IT vs DE



DDR5 — Distribuzione capacità: IT vs DE



DDR5 — Distribuzione frequenza: IT vs DE



DDR4 capacità: distribuzione quasi identica tra Italia e Germania; entrambi i mercati sono dominati da moduli 16 GB e 32 GB, con code marginali su 64 GB e oltre


DDR4 frequenza: forte concentrazione su 3200 MT/s in entrambi i mercati, seguita da 3600 MT/s

DDR5 capacità: anche qui il picco è condiviso, ma la coda è più lunga e più marcata in Germania che ha il 23% di kit da 64 GB contro il 16% dell'Italia, e ospita anche configurazioni enterprise rare (192-256 GB) assenti o quasi in Italia

DDR5 frequenza: 6000 MT/s è lo standard dominante in entrambi i mercati (58% DE, 55% IT); la Germania mostra una coda leggermente più estesa verso l'alto (7600 MT/s presente solo in DE)

Confronto DDR4 vs DDR5: il "centro" della distribuzione è identico tra i due mercati in entrambe le categorie, le differenze di prezzo osservate in precedenza non sono quindi spiegabili da un mix di specifiche sistematicamente diverso

DDR5: maturità o è ancora una nicchia?



Per i volumi assoluti è utilizzata una scala logaritmica ($10^1 = 10$, $10^2 = 100$) per confrontare nella stessa vista ordini di grandezza differenti.

Sviluppi futuri e conclusioni

Obiettivi raggiunti:

- Repository dati puliti, deduplicati e comparabili costruito con successo (656 record consolidati, 4 dimensioni di data quality validate), riutilizzabile da pricing analyst, system integrator e consumatori tech
- Confronto tra i mercati IT e DE:
 - a. *Differenziale di prezzo IT/DE per categoria*: quasi nullo su DDR4, marcato su DDR5 (Germania più cara, trainata dai kit enterprise ad alta capacità)
 - b. *Distribuzione assortimento (SKU) tra mercati e categorie*: DDR4 resta la categoria con più SKU in entrambi i mercati
 - c. *Differenze di capacità/frequenza tra mercati*: Il picco delle distribuzioni di capacità e frequenza è lo stesso tra Italia e Germania, in entrambe le categorie (DDR4 e DDR5); la Germania mostra solo una coda più estesa di kit DDR5 enterprise, coerente col differenziale di prezzo osservato
 - d. *Maturità assortimento DDR5 vs DDR4*: DDR4 resta dominante in volume di SKU, DDR5 ha già raggiunto pari varietà tecnica di configurazioni (*dati relativi ai grafici della slide precedente*)

Obiettivi non raggiunti: non è stato calcolato un indicatore di prezzo normalizzato per capacità (€/GB), utile in particolare per lo stakeholder System Integrator/PC Builder per le seguenti motivazioni:

- quale base di prezzo usare (rawPrice puro o comprensivo di spese di spedizione, disomogenee tra shop)
- su quale unità normalizzare (capacità totale del kit vs capacità per singolo modulo)
- come trattare gli outlier enterprise ad alta capacità già osservati nei boxplot, che distorcerebbero una media semplice

Sviluppi futuri:

- Automatizzare l'ingestion tramite uno scraper o pipeline schedulata
- Estendere la copertura ad altri marketplace europei (es. FR, ES) riutilizzando i pattern regex language-agnostic già sviluppati
- Calcolo di un indicatore di prezzo normalizzato per capacità

Conclusioni: Nel campione osservato, per quanto riguarda le memorie DDR5, il mercato italiano risulta nettamente più conveniente rispetto a quello tedesco, mentre, per le memorie DDR4 i due mercati risultano sostanzialmente equivalenti.